

Modelo de predicción de ingresos basado en la GEIH para Bogotá

Mariana Correa, Rodrigo Iriarte, Marcel Montesdeoca , y Juan E. Moncada

Link repositorio: https://github.com/jmoncadal/taller_1

Resumen

El bajo nivel de recaudo tributario en Colombia sigue siendo un desafío en la actualidad para la sostenibilidad y redistribución de las finanzas públicas. Una de las causas de este problema es el subreporte de ingresos de una parte de la población. Este documento tiene el propósito de analizar diferentes propuestas para abordar este problema; entendiendo causantes del ingreso por hora y predictores del mismo. Adicionalmente, se analizará la brecha salarial de género y las principales causas de esta desigualdad en el mercado laboral. De acuerdo con lo anterior, se pretende aportar al diseño de modelos que permitan disminuir el subreporte de ingresos de la población; contribuyendo a un sistema tributario más eficiente.

Keywords: Predicción, Impuestos, Big Data, Salarios.

1. Introducción

En Colombia, uno de los principales problema es el bajo recaudo de impuestos, lo que genera impactos negativos en las finanzas públicas. Hasta marzo del 2025, La DIAN recaudó 49,5 billones de pesos, una cifra muy baja teniendo en cuenta que la meta del año es de 300 billones, la cantidad necesaria para inversión en proyectos sociales (La República, 2023). Esto se debe a varios factores, como la elusión y evasión de impuestos. Uno de los mecanismos más comunes es que los contribuyentes reportan un salario menor al que realmente ganan, como una manera de reducir su obligación tributaria. Por ejemplo, en Colombia, los trabajadores independientes son más probables a declarar un menor salario frente a la DIAN, y también en encuestas de hogares realizadas por el DANE. La razón principal es que no existe un tercero que pueda verificar dicha información, a diferencia de los trabajadores formales (Rocha,2013). Con mejor información sobre los salarios, los hacedores de política pública pueden asegurar una recolección más eficiente, y esto se traduciría a una mejor asignación en general.

Los datos que se utilizaron para son de la Gran Encuesta Integrada de Hogares (GEIH) de 2018, elaborada por el DANE y se escogieron las variables más relevantes para la solución del problema. La base de datos limpia contiene 14617 observaciones, a nivel individual en Bogotá. Para cada individuo hay variables socioeconómicas relevantes como el estrato; otras características observables como la edad, nivel de educación, género y otras características relacionadas al mercado laboral, como la formalidad.

Después de un análisis de literatura y de los modelos establecidos se llegó a varios resultados. En primer lugar, se encontró que a medida que aumenta la edad, el ingreso tiende a aumentar, hasta que llega a una edad pico, donde el salario empieza a caer por factores como disminución en la productividad u obsolescencia en las habilidades. En segundo lugar, y estrechamente relacionado con lo anterior, se encontró que existe una brecha salarial de género determinada por factores como discriminación. Del mismo modo, existen diferencias en la edad pico de hombres y mujeres lo que refleja trayectorias laborales diferentes por género. Finalmente se estimaron diferentes modelos para determinar que el modelo 6 es el óptimo para predecir, al incluir no linealidades e interacciones relevantes, logra el mejor balance entre sesgo y varianza.

2. Datos

La Gran Encuesta Integrada de Hogares (GEIH, en adelante) es una encuesta mediante la cual se solicita información sobre las condiciones de empleo de las personas, además de las características generales de la población como sexo, edad, estado civil y nivel educativo a una muestra de colombianos. La información recolectada por esta encuesta puede ser útil para diseñar un modelo de predicción de ingreso, dado que contiene una gran cantidad de datos y variables de interés para predecir el nivel de ingreso de las personas en Colombia.

En la economía laboral, se han realizado varios intentos para dar explicación a qué determina los salarios y las disparidades entre los niveles educativos y el sexo. Dentro de las variables que se consideran más importantes son: nivel educativo, experiencia laboral, edad y sexo. Así pues, la GEIH reúne esta información, lo que demuestra su utilidad para ser usada en este estudio.

2.1. Descripción de los datos

Para acceder a estos datos, fue necesario realizar un scrapeo de una página web dinámica. Sin embargo, si bien la página principal era dinámica, al revisar de dónde solicitaba la información, se puede ver que es una página estática. Así, el proceso de recolección de datos fue un proceso iterativo que hacía solicitudes al HTML de cada página estática donde se almacenaban los datos y se fueran guardando en un dataframe. Este método es coherente con las guías de GitHub, ya que no hubo mayores limitaciones y se siguieron las buenas prácticas.

2.2. Limpieza de datos

El objetivo del estudio se concentró en los mayores de edad que trabajaban. Por lo tanto, se restringió la muestra a las edades mayores de 18 que efectivamente se reportaron como ocupados. Adicionalmente, se vio que en algunos grupos etarios mayores de 80 se presentaban valores atípicos que se consideraron no representativos de la muestra, por lo que se decidieron eliminar esas observaciones. Se modificó el nombre de las variables dicótomas para que su identificación fuera más fácil y, para las variables con más de una categoría, se cambió su estructura de datos para que fueran factores. Esto facilitó la interpretación de las regresiones y la creación de gráficos para explorar los datos.

En principio, la base contaba con muchos missing values. Sin embargo, al limitar la base a los trabajadores entre los 18 y 82 años, los missing values cayeron sustancialmente. En concreto, para nuestros controles y variable dependiente, todos tenían un 0 % de missing values. Los únicos valores que tenían valores faltantes fueron *maxEducLevel* con 1 missing. Por lo tanto, se consideró innecesario hacer una imputación de los valores.

2.3. Exploración de datos

Por un lado, uno de los principales intereses de la economía laboral es la relación entre salario y educación. Así pues, se exploró el comportamiento de los datos de ingreso de acuerdo con cada grupo educativo. Esta información está resumida en la Figura 1. Se puede observar que a medida que aumenta el nivel educativo, los ingresos tienden a ser más altos. Curiosamente, los datos tienden a concentrarse para todos los grupos, excepto educación terciaria, donde presentan una dispersión comparativamente mayor. Además, se ve que, para todos los niveles educativos, los hombres tienden a tener salarios más altos, comportamiento que se nota aún más en la educación terciaria.




Figura 1: Distribución ingresos por nivel de educación y sexo

Al desglosar los salarios por los grupos etarios, se ve que a medida que aumenta el grupo etario, los salarios tienden a presentar una caída para los dos sexos. Particularmente, se ve que llegan a un máximo entre los 45 y 55 años de edad. Este comportamiento se presenta tanto para mujeres como para hombres.




Figura 2: Salario por sexo y grupo etario

3. Perfil edad-salario

La brecha de salario-edad ha sido uno de los temas de interés de la economía laboral. En concreto, la evidencia empírica enseña que hay una relación de 'U' invertida entre la edad y los salarios para la mayoría de los mercados laborales y ocupaciones. Trabajos como el de Huggett, Ventura y Yaron,¹ describen que el pico de salario llega alrededor de los 50 años. Para nuestro

1. Mark Huggett, Gustavo Ventura y Amir Yaron, «Sources of lifetime inequality», *American Economic Review* 101, n.º 7 (2011): 2923-2954, <https://doi.org/10.1257/aer.101.7.2923>.

caso, queremos establecer si esta relación documentada por la literatura se presenta en Bogotá, y en caso de que sí, cuándo es el pico de salarios para la población.

El modelo 1, busca entender la relación entre salarios y la edad. Como muestra la literatura, se debe esperar que, hasta cierta edad, el salario debería ser mayor. Ahora bien, al incluir el término al cuadrado lo que se desea es permitirle al modelo capturar cómo cambia ese aumento. Es decir, la variación del incremento del salario dependiendo de la edad. Como se mencionó en el párrafo anterior, la relación que se espera es negativa, indicando que a mediada que aumenta la edad, los salarios tienden a disminuir. Al correr el modelo se obtienen los siguientes resultados.

$$\ln \text{salario}_i = \beta_0 + \beta_1 \text{age}_i + \beta_2 \text{age}_i^2 + \epsilon_i \quad (1)$$

Como se discutió anteriormente, la magnitud de la edad es positiva, indicando que a mayor edad mayor salario. En concreto, cumplir un año adicional se relaciona con un aumento del 5,3 % en el salario por hora, manteniendo lo demás constante. Ahora bien, al revisar el coeficiente de la edad al cuadrado, se observa que es negativo, tal y como se esperaba. Así, si bien a medida que entre más años se tenga más salario por hora se gana, esto tiende a decrecer. Específicamente, el aumento de la edad se relaciona con una disminución del crecimiento del salario del 0,1 %, manteniendo todo lo demás constante. Para los dos coeficientes, las estimaciones son significativas al 1 %. Entonces, bajo estas condiciones, se confirma que el perfil salario-edad para Bogotá es coherente con lo descrito en la literatura.

Cuadro 1: Regresión perfil salario-sexo

	Logaritmo ingreso
Edad	0.058*** (0.003)
Edad ²	-0.001*** (0.00004)
Constante	7.552*** (0.064)
Observaciones	14,617
R ²	0.022
R ² Ajustado	0.022
Error estándar residual	0.822
Estadístico F	168.100***
Errores estándar en paréntesis *p<0.1; **p<0.05; ***p<0.01	

Ahora bien, la concavidad de esta relación necesariamente implica la existencia de un máximo. Lo que nos interesa es, por tanto, cuál es la edad promedio para la que se obtiene el mayor salario en Bogotá. Como se muestra en la Figura 3, el máximo se consigue a los 41.6 y, después, comienza a descender progresivamente. Sin embargo, el desempeño potencialmente predictivo del modelo no es particularmente bueno. El R cuadrado nos indica que el modelo explica solo el 2 % de la variabilidad en el ingreso es explicado por el modelo. Esto indica que solo la edad no es suficiente para explicar los cambios en los salarios; esto, junto con la existencia asegurada de variables omitidas, indica que el modelo debe incluir más variables.




Figura 3: Relación salario y edad

4. Perfil salario-sexo

La ecuación condicional a estimar es la ecuación 2 donde X es un vector de variables de control que contiene: *age*, la cual permite capturar cuál es el salario a diferentes edades y que se pueda comparar cual es el salario de hombres y mujeres a la misma edad. *age*² que hace referencia al término de edad al cuadrado y es relevante ya que se puede ver la relación no lineal entre edad y salario, pues permite ver que los ingresos son crecientes hasta cierta edad (“peak age”) y a partir de ahí empiezan a decrecer. *experience* es importante ya que los ingresos aumentan con la experiencia y por ende, a diferente niveles de experiencia hay diferentes niveles de ingreso. *experience*² muestra la relación no lineal entre la experiencia y los ingresos laborales, ya que al inicio los rendimientos de la experiencia son crecientes hasta un punto en el que empiezan a disminuir debido a reducción de productividad. *maxEducLevel* muestra el máximo nivel de educación alcanzado, el cual es fundamental para entender diferencias en brecha salarial, ya que personas con diferentes niveles de educación van a tener diferentes ingresos.

$$\ln \text{ingtot}_h = \beta_1 + \beta_2 \text{bin_female} + \theta X + u \quad (2)$$

También contiene variables socioeconómicas y propias del mercado laboral como: *estrato1* muestra en qué estrato de la población se encuentra y es una buena proxy para el nivel socioeconómico de las personas y condiciones asociadas; pues una mujer de estrato 1 puede tener diferentes oportunidades a una mujer de estrato 5. *cuentaPropia* es una variable que toma el valor de 1 si la persona es cuenta propia y 0 de lo contrario. Esta variable es pertinente debido a que pueden existir diferencias en el ingreso dependiendo de la modalidad de trabajo del individuo. Por ejemplo, una persona que trabaja cuenta propia está sujeto al capital que tenga en ese momento; mientras que un asalariado siempre recibirá el mismo salario, lo que supone mayor estabilidad salarial (Guataquí; García, 2009). Finalmente, *sizeFirm* representa el tamaño de la firma donde se encuentra la persona, lo cual representa un buen control porque captura diferencias en la estabilidad y el capital físico. Por ejemplo, firmas más pequeñas dependen más de su capital físico y representan más riesgo; mientras que empresas más grandes tienen una mayor estabilidad laboral y beneficios y pueden

acceder a mejores salarios .

Vale la pena resaltar que se consideró la inclusión de la variable *oficio*, que contiene la ocupación de cada individuo. Sin embargo, se concluyó que no es un buen control puesto que en la brecha salarial de género hay un problema de selección; lo que genera que el sexo determine el oficio (BID, 2023).

Ahora bien, en el modelo incondicional (sin controles) se encontró que, en promedio, las mujeres tienen un salario 9.1 % menor que el de los hombres, manteniendo todo lo demás constante. Mientras que en el modelo condicional (agregando controles), las mujeres ganan en promedio un 14.5 % menos que los hombres, *ceteris paribus*. Esto sugiere que en el modelo incondicional se está capturando la brecha salarial sin distinguir entre características observables de los individuos, por lo que no es clara la razón de esta brecha. No obstante, al agregar los controles, se puede atribuir mejor el efecto al género, pues se tiene en cuenta el impacto de características relevantes como educación, experiencia, estrato y los demás controles incluidos.

Cuadro 2: Regresión perfil salario-sexo

	<i>Variable dependiente: $\ln(\text{ingreso hora})$</i>	
	(1) OLS	(2) FWL
Mujer	-0.091*** (0.014)	-0.145*** (0.010)
Constante	8.672*** (0.009)	
Controles	No	Sí
Observaciones	14,617	14,616
R^2	0.003	0.014
R^2 ajustado	0.003	0.014
Error estándar residual (df = 14615)	0.831	0.603
Estadístico F (df = 1; 14615)	43.960***	206.100***

Nota: En el modelo 2, el R^2 reportado es parcial. Los controles incluidos son: edad, edad², experiencia, experiencia², nivel educativo, estrato, cuenta propia y tamaño de la firma. Errores estándar en paréntesis. *p<0.1; **p<0.05; ***p<0.01

Vale la pena mencionar que los coeficientes de ambos modelos son estadísticamente significativos al 1 %. Además, al comparar el R^2 se puede ver que en el modelo incondicional, el género explica solo 0.3 % la variación de los ingresos. Debido a que en este modelo se utilizó FWL, el R^2 es parcial y aísla la variabilidad de la variable de interés sobre la variable dependiente; por lo cual, en este modelo, el género explica en 1.4 % la variabilidad de los ingresos laborales. Esto muestra que el modelo condicional se ajusta mejor a la muestra y que los controles explican una gran parte de los diferentes salarios. Adicionalmente, el coeficiente de interés (β_2) se hace más grande cuando se incluyen controles, mostrando una mayor brecha salarial. Esto puede demostrar que una de las razones por las cuales existe una brecha salarial de género es la discriminación; dado que al controlar por diferentes características que también son determinantes del salario, la brecha se sigue amplía. En este modelo, no podemos asegurar que se debe a un problema de selección por parte de las mujeres; ya que por la naturaleza de la variable oficio, este es un mal control. Se necesita una estimación diferente para analizar este fenómeno.

Por otro lado, el error estándar del modelo por el método de FWL es de 0.01009, y el estimado por FWL y Bootstrap es de 0.01016. Los errores son muy parecidos lo que quiere decir que ambos




Figura 4: Predicciones ingreso horario por edad y sexo

modelos generan estimadores robustos. Adicionalmente, esto da indicios que el modelo 1 cumple con los supuestos de la distribución de los errores asociados a un estimador BLUE.

La edad pico para las mujeres es 43.2 y para los hombres 46.8; el error estándar para las mujeres es de 0.681 y el de los hombres es de 0.709, lo que sugiere estimaciones más robustas al ser tan parecidos. Los intervalos de confianza de la edad pico no se superponen por lo que se puede decir que la diferencia de esta edad es estadísticamente significativa. Esto sugiere que la trayectoria de los ingresos es diferente para cada género y podría ser por interrupciones en la vida laboral de las mujeres por factores como la maternidad o oportunidades limitadas.

Adicionalmente, los intervalos de confianza del salario sí se superponen, lo que demuestra que no hay evidencia suficiente para decir que existe una brecha salarial de género cuando se observa por cada edad. No obstante, hay evidencia que demuestra que esta brecha es existente y persistente, por lo que la falta de algunos controles o de un modelo más complejo podría explicar la similitud estadística. Cabe mencionar, que antes de la edad pico, los intervalos de confianza se traslapan más que después de la edad pico, lo que puede ser explicado porque cuando las mujeres son más jóvenes empiezan la trayectoria de la vida laboral más similar a los hombres, y es cuando empiezan a dedicarse a otros trabajos, labores del hogar, maternidad que empiezan a rezagarse en los salarios, sin olvidar la discriminación de género explicada anteriormente.

5. Predicción de ingresos

Se estimaron varios modelos lineales por Mínimos Cuadrados Ordinarios (MCO) para

$$y_i \equiv \ln(\text{ingtot_h})_i,$$

combinando polinomios en edad, experiencia y horas trabajadas; dummies de sexo, formalidad, y conjuntos de dummies para estrato, oficio, nivel educativo y tamaño de empresa.

Los modelos fueron estimados sobre una muestra dividida en una proporción 70/30, utilizando la semilla 10101. El 70 % de los datos se destinó al entrenamiento y el 30 % restante a la validación.

Para seleccionar el mejor modelo se empleó como métrica de evaluación el *Root Mean Squared Error* (RMSE).

5.1. Resultados

Cuadro 3: Desempeño de modelos (train / test)

Modelo	RMSE (in-sample)	R^2	R^2 ajustado	N	Prám.	RMSE (out of sample)
Modelo 1	0,762	0,034	0,034	10 220	3	0,781
Modelo 2	0,775	0,002	0,002	10 220	2	0,787
Modelo 3	0,574	0,453	0,452	10 219	23	0,582
Modelo 4	0,540	0,516	0,511	10 219	101	0,551
Modelo 5	0,513	0,562	0,558	10 219	106	0,525
Modelo 6	0,506	0,574	0,567	10 219	160	0,523
Modelo 7	0,494	0,595	0,577	10 219	463	0,571
Modelo 8	0,464	0,642	0,593	10 219	1725	0,587

Los modelos base (1–3) muestran un desempeño apenas superior al de un error estándar de referencia de 0.80, con *RMSE* fuera de muestra de 0.781, 0.787 y 0.582, e *in-sample* de 0.762, 0.775 y 0.574, respectivamente. El número de parámetros es 3, 2 y 23, y el mejor de este grupo es el Modelo 3, que incluye controles diseñados para abordar el sesgo discutido en la sección anterior. Para mejorar el ajuste, estimamos especificaciones adicionales. Primero, el Modelo 4 incorpora efectos fijos de oficio para capturar heterogeneidad ocupacional. El error cae a un *RMSE in-sample* de 0.540 y *out-of-sample* de 0.551, con 101 parámetros. Luego, el Modelo 5 añade horas trabajadas, elimina interacciones con edad y sexo, e introduce formalidad y las interacciones sexo×formalidad y sexo×nivel educativo. El *RMSE* se reduce a 0.513 (*in-sample*) y 0.525 (*out-of-sample*), con 106 parámetros; es el segundo mejor desempeño fuera de muestra.

Con el fin de minimizar el error de predicción, el Modelo 6 permite no linealidades (polinomios e interacciones), reteniendo únicamente términos que reducen el error. Es la mejor especificación fuera de muestra: *RMSE* 0.506 (*in-sample*) y 0.523 (*out-of-sample*), con 160 parámetros. A partir de ese mínimo, preservamos las interacciones pero normalizamos los polinomios a grado tres por interpretabilidad económica (Modelo 7). El *RMSE* empeora a 0.494 (*in-sample*) y 0.571 (*out-of-sample*), con 463 parámetros. Finalmente, el Modelo 8 cruza todas las variables con polinomios de primer grado (interacciones amplias) para ilustrar la parametrización y el compromiso sesgo–varianza. Aunque el ajuste dentro de muestra continúa mejorando (*RMSE* 0.464), el desempeño fuera de muestra se deteriora a 0.587, con 1.725 parámetros, evidenciando sobreajuste. En síntesis, el *RMSE* fuera de muestra describe la típica curva en U: mejora hasta el **Modelo 6** (0.523) y luego **augmenta** al incrementar la complejidad. Las ganancias *in-sample* no se traducen en generalización cuando la parametrización crece en exceso.

5.2. ¿Por qué el Modelo 6 es la mejor especificación?

La especificación (6) obtiene el menor *RMSE* porque combina no linealidades e interacciones que capturan heterogeneidades clave del mercado laboral. En lugar de promediar comportamientos, el modelo aproxima con mayor precisión los perfiles de ingreso a lo largo del ciclo de vida y las diferencias sistemáticas entre grupos, lo que reduce errores grandes en la muestra de prueba.




Figura 5: Distribución de errores de predicción del mejor modelo

Los términos polinomiales en variables de trayectoria (edad y antigüedad en la empresa) reproducen curvaturas típicas del perfil salarial —crecimiento inicial, mesetas y rendimientos decrecientes— sin imponer formas rígidas. A su vez, las interacciones por género, formalidad y tamaño de firma permiten que los retornos marginales varíen entre subpoblaciones, ajustando niveles y pendientes de las curvas de predicción y evitando que el modelo “promedie” conductas de grupos con dinámicas distintas.

La inclusión de variables de contexto ocupacional y educativo, y su interacción con la formalidad, absorbe segmentaciones persistentes (oficio, credenciales y calidad de emparejamiento) que, de otro modo, quedarían como heterogeneidad no observada. El resultado no debe interpretarse como causal, sino como un ajuste predictivo superior: el modelo identifica patrones estables en la combinación de ocupación, educación, formalidad y tamaño de firma. En síntesis, la ganancia en *RMSE* proviene de tres mecanismos complementarios: (i) capturar curvaturas reales en los perfiles de ingresos (no linealidades bien especificadas), (ii) permitir que los retornos varíen entre grupos relevantes (interacciones que introducen heterogeneidad de pendientes y niveles) y (iii) absorber segmentaciones persistentes del entorno laboral (efectos de oficio, estrato, tamaño de empresa y educación). Este equilibrio mejora el compromiso sesgo-varianza: el modelo es lo bastante rico para reducir errores, sin perder generalización en la muestra de prueba. Como verificación adicional, conviene contrastar su estabilidad con validación cruzada (ver última sección).

5.3. Distribución de errores (modelo 6)

Con la especificación de menor error de predicción, la distribución del residuo $e \equiv y - \hat{y}$ en la muestra de prueba está centrada en cero y presenta colas acotadas. En la figura, la mediana es 0,000 y los percentiles 2,5 y 97,5 se ubican en $-0,981$ y $1,177$ log-puntos, respectivamente, lo que sugiere una ligera asimetría a la derecha (cola positiva algo más pesada).

Casos *miss the mark*

Existen observaciones en ambas colas:

- **Cola inferior** ($e < -0,98$): concentra los casos más útiles para tamizaje de riesgo de la Dirección de Impuestos y Aduanas Nacionales (DIAN). Corresponden a individuos que reportan ingresos muy por debajo de los esperados, dado su vector de covariables. Esto no

prueba evasión por sí mismo; puede obedecer a variables omitidas (bonificaciones, comisiones, patrimonio, entre otros), medición imperfecta de de covariables que podrían forzar extrapolación del modelo.

- **Cola superior** ($e > 1,18$): los grandes residuos suelen reflejar subpredicción del modelo para perfiles de muy altos ingresos o no linealidades marcadas, más que un patrón típico de subreporte; desde la óptica de fiscalización, tienden a ser “falsos negativos”.

Limitaciones

Independientemente del modelo, la base disponible es limitada. Para fortalecer el tamizaje y reducir sesgos por omisión se requiere ampliar, adicionar covariables y la calidad de medición. Esto debería acotar los *misses* en ambas colas y mejorar la precisión predictiva.

5.4. Resultados de LOOCV

Cuadro 4: Comparativo de desempeño: LOOCV vs validación 30/70

Modelo	LOOCV	Validación 30/70
	LOOCV (RMSE)	RMSE (30/70)
Modelo 5	0.520	0.525
Modelo 6	0.517	0.523

LOOCV y comparación con validación 30/70. Para los dos modelos con menor error predictivo, el RMSE por *LOOCV* es de 0.520 (Modelo 5) y 0.517 (Modelo 6), mientras que con el enfoque de partición 70/30 es de 0.525 y 0.523, respectivamente (Cuadro 4). En ambos criterios se preserva el orden: el Modelo 6 domina al Modelo 5. Las diferencias entre *LOOCV* y 70/30 son pequeñas ($\approx 0,005$ – $0,006$ puntos de RMSE, es decir, $\sim 1\%$), lo que sugiere estabilidad del desempeño y pequeño sesgo por la elección del *split*.

Relación con medidas de influencia. En modelos lineales, el residuo bajo *LOOCV* para la observación i se calcula como

$$\tilde{e}_i = \frac{e_i}{1 - h_i}, \quad \text{lo que implica que} \quad \text{RMSE}_{\text{LOOCV}} = \sqrt{\frac{1}{n} \sum_{i=1}^n \tilde{e}_i^2},$$

donde e_i es el residuo ordinario y h_i es el *leverage*. Este resultado implica que observaciones con alta influencia (es decir, alto h_i) amplifican los residuos ajustados $\tilde{e}_i$. En este contexto, si existiera un grupo reducido de observaciones altamente influyentes, se esperaría una diferencia notable entre $\text{RMSE}_{\text{LOOCV}}$ y $\text{RMSE}_{70/30}$. La similitud observada entre ambos indicadores sugiere que no hay evidencia de tales observaciones influyentes, lo que refuerza la validez de los resultados de generalización.

Referencias

Huggett, Mark, Gustavo Ventura y Amir Yaron. «Sources of lifetime inequality». *American Economic Review* 101, n.º 7 (2011): 2923–2954. <https://doi.org/10.1257/aer.101.7.2923>.